

Aspectos Matemáticos y Computacionales del
Aprendizaje Automático
Posgrado en Ciencias Matemáticas
Universidad de Sonora

Jose Crispín Ruiz Pantaleón
Gerardo Mauricio Toledo Acosta

19 de febrero de 2026

Descripción del Curso

El análisis moderno de conjuntos de datos desafía la intuición geométrica y las herramientas clásicas de cálculo debido a la alta cardinalidad de éstos. En este contexto es que emergieron en años recientes dos marcos teóricos de gran relevancia: *Topological Data Analysis* y *Geometric Deep Learning*. Los cuales encuentran su fundamento en la síntesis de diversas estructuras matemáticas (topológicas, diferenciales, lineales, algebraicas, combinatorias, entre otras) y diversos aspectos computacionales (para las correspondientes implementaciones).

Este curso propone, por un lado, estudiar los fundamentos matemáticos de tales marcos teóricos, y por otro, utilizar las correspondientes implementaciones computacionales para explorar aplicaciones de la teoría a problemas actuales, tales como la representación y el análisis de ciertas clases relevantes de bases de datos. Por la naturaleza teórica-práctica de la propuesta, se hará énfasis en:

- Determinar e interpretar estructuras sobre los conjuntos de datos a través de invariantes topológicos.
- Proyectar subconjuntos de espacios multidimensionales preservando aspectos geométricos globales y/o locales subyacentes en los conjuntos de datos.
- Diseñar aproximadores (universales) de funciones con restricciones de simetría.

Para lo anterior, este curso se organiza en tres módulos secuenciales en los que se integra la correspondiente teoría matemática con aplicaciones concretas en el análisis de datos.

- *Módulo 1.* Herramientas para visualizar y explorar la geometría de datos en espacios de alta dimensión.
- *Módulo 2.* Estudio computacional de sus propiedades topológicas intrínsecas mediante homología persistente y teoría de Morse discreta.
- *Módulo 3.* Aproximadores universales de funciones, analizando tanto modelos no restrictivos (como MLPs) como arquitecturas que incorporen simetrías geométricas (CNNs y GNNs) para mapear entre espacios multidimensionales.

Introducción

El aprendizaje automático es, en su esencia, una disciplina profundamente matemática. Si bien es común escuchar que “el machine learning no es más que estadística aplicada”, esta perspectiva, aunque válida, representa solo una faceta de un prisma mucho más rico y complejo. La realidad es que los algoritmos y métodos que sustentan el aprendizaje automático moderno encuentran sus raíces en diversas ramas de las matemáticas: geometría diferencial, álgebra lineal y multilineal, topología algebraica, teoría de la medida, análisis funcional y optimización convexa, entre otras.

Esta visión multidisciplinaria no es meramente académica; es fundamental para comprender por qué ciertos algoritmos funcionan, cuándo fallan, y cómo pueden ser mejorados o adaptados a problemas específicos. Un practitioner que comprende únicamente la implementación computacional de un algoritmo es como un arquitecto que conoce solo los materiales pero no las leyes de la física que gobiernan las estructuras.

La Geometría del Aprendizaje

Desde una perspectiva geométrica, los datos pueden entenderse como puntos en espacios de alta dimensión, y muchos problemas de aprendizaje automático se reducen a encontrar estructuras geométricas significativas en estos espacios. El análisis de componentes principales (PCA), por ejemplo, no es simplemente una técnica de reducción de dimensionalidad basada en la maximización de varianza; es la búsqueda de los subespacios lineales que mejor aproximan la geometría intrínseca de los datos.

Los algoritmos de clustering como k-means operan bajo supuestos geométricos específicos sobre la forma y separación de los grupos en el espacio de características. Las máquinas de vectores de soporte (SVM) construyen hiperplanos separadores óptimos, transformando problemas de clasificación en

problemas de geometría computacional en espacios de Hilbert de dimensión potencialmente infinita.

Los métodos de embedding como t-SNE y UMAP buscan preservar estructuras geométricas locales al proyectar datos de alta dimensión a espacios de menor dimensión, utilizando conceptos de geometría riemanniana y teoría de variedades.

El Álgebra como Lenguaje Universal

El álgebra lineal proporciona el vocabulario fundamental del aprendizaje automático. Las redes neuronales, en su forma más básica, son composiciones de transformaciones lineales y no lineales que pueden expresarse elegantemente en términos de productos matriciales y operaciones tensoriales.

Pero el álgebra del machine learning va más allá de la manipulación de matrices. El álgebra multilineal y la teoría de tensores son esenciales para comprender arquitecturas modernas como las redes convolucionales y los mecanismos de atención. Los métodos de factorización matricial y tensorial revelan estructuras latentes en los datos, desde sistemas de recomendación hasta modelos de temas en procesamiento de lenguaje natural.

El álgebra abstracta también encuentra aplicaciones sorprendentes: la teoría de grupos ayuda a entender las simetrías en redes neuronales convolucionales, mientras que la teoría de categorías comienza a ofrecer marcos unificadores para entender la composicionalidad en el aprendizaje profundo.

La Topología de los Datos

La topología, tradicionalmente vista como una rama abstracta de las matemáticas, ha emergido como una herramienta poderosa para el análisis de datos. La topología algebraica proporciona invariantes que capturan la "forma" de los datos de maneras que van más allá de las métricas tradicionales.

El análisis topológico de datos (TDA) utiliza conceptos como complejos simpliciales y homología persistente para identificar características topológicas robustas en conjuntos de datos ruidosos. Estas técnicas han mostrado ser particularmente útiles en aplicaciones que van desde la neurociencia hasta la ciencia de materiales.

Los mapas de difusión y otros métodos de aprendizaje de variedades (manifold learning) se basan en conceptos topológicos para descubrir la estructura intrínseca de datos que residen en variedades de baja dimensión embebidas en espacios de alta dimensión.

Capítulo 1

Aprendizaje Automático

El aprendizaje automático, o *Machine Learning*, consiste en ...

Concepto	NumPy
$v \in \mathbb{R}^n$	<code>np.array(...)</code>
$A \in \mathbb{R}^{m \times n}$	<code>np.array([[...], [...]])</code>
$u^\top v$	<code>u @ v</code>
$\ v\ _2$	<code>np.linalg.norm(v)</code>
Ax	<code>A @ x</code>
$A^\top$	<code>A.T</code>
A^{-1}	<code>np.linalg.inv(A)</code>
Valores propios	<code>np.linalg.eig(A)</code>
SVD	<code>np.linalg.svd(A)</code>
Comparación numérica	<code>np.allclose(X,Y)</code>

Capítulo 2

Reducción de Dimensionalidad

La reducción de dimensionalidad consiste en encontrar representaciones de menor dimensión que preserven la información esencial contenida en datos de alta dimensión. En esencia, consiste en la construcción de proyecciones $f : \mathbb{R}^D \rightarrow \mathbb{R}^k$ donde $k \ll D$, que proyectan observaciones desde el espacio original de características hacia un subespacio de dimensión reducida, manteniendo propiedades geométricas, topológicas o estadísticas relevantes para la tarea en cuestión.

Esta transformación no es meramente una compresión de datos; su objetivo es también revelar la estructura intrínseca subyacente en conjuntos de datos complejos, permitiendo tanto la visualización efectiva de patrones que serían imperceptibles en espacios de alta dimensión, como la mejora significativa del rendimiento de algoritmos de aprendizaje automático al mitigar la maldición de la dimensionalidad, reducir el ruido, y facilitar la identificación de características discriminativas que de otro modo permanecerían ocultas en la complejidad del espacio original.

Sea $\mathbb{R}^D$ el espacio euclidiano D -dimensional, S^{D-1} la esfera unitaria en $\mathbb{R}^D$ y $\|\cdot\|$ la norma euclidiana usual. Denotamos además por $\|\cdot\|_p$ la p -norma de Minkowski para $p \geq 1$ entero dada por

$$\|x\|_p = \|(x_1, \dots, x_D)\|_p = \left(\sum_{j=1}^D |x_j|^p \right)^{\frac{1}{p}}.$$

Dado un conjunto finito A , denotamos por $|A|$ su cardinalidad.

A lo largo de estas notas diremos que un conjunto de datos (dataset) es un conjunto finito $A \subset \mathbb{R}^D$, donde D es típicamente un valor grande $D \geq 4$.

Abusando de la notación, también denotaremos al conjunto A por la matriz $A \in \mathcal{M}_{N \times D}(\mathbb{R})$ donde $|A| = N$ en la cual cada fila es un elemento de A dado por sus coordenadas en la base canónica.

Estos conjuntos representan datos u observaciones sobre algún fenómeno. Cada instancia está representada por varias características (features, variables predictoras).

Cuando D es grande, puede ser necesario encontrar una proyección $p : \mathbb{R}^D \rightarrow \mathbb{R}^{D_0}$ donde $D_0 \ll D$ que preserve, lo mejor posible, ciertas propiedades del conjunto A . Esto con dos finalidades:

- Visualizar los datos A en 2 o 3 dimensiones, es decir, $D_0 \in \{2, 3\}$.
- Obtener nuevas variables representando el mismo fenómeno de tal manera que su manejo computacional sea más eficiente.
- Reducir el ruido en los datos cuando estos pertenecen a un espacio de menor dimensión pero están corrompidos por ruido de alta dimensión.

En este capítulo estudiaremos varios métodos para realizar reducción de dimensionalidad.

2.1. Fundamentos

Sea

$$\mu(A) = \frac{1}{|A|} \sum_{a \in A} a \in \mathbb{R}^D$$

el promedio, o media aritmética, de los datos A .

Proposición 2.1.1. *Para un conjunto de datos $A = \{x_1, x_2, \dots, x_n\} \subset \mathbb{R}^D$, el punto z que minimiza*

$$f(z) = \sum_{i=1}^n \|x_i - z\|^2$$

es precisamente la media aritmética $\mu(A) = \frac{1}{n} \sum_{i=1}^n x_i$.

Demostración. Expandamos la función objetivo:

$$f(\mu) = \sum_{i=1}^n \|x_i - \mu\|^2 \quad (2.1)$$

$$= \sum_{i=1}^n (x_i - \mu)^T (x_i - \mu) \quad (2.2)$$

$$= \sum_{i=1}^n (x_i^T x_i - 2x_i^T \mu + \mu^T \mu) \quad (2.3)$$

$$= \sum_{i=1}^n x_i^T x_i - 2\mu^T \sum_{i=1}^n x_i + n\mu^T \mu \quad (2.4)$$

Para encontrar el mínimo, tomamos la derivada con respecto a μ e igualamos a cero:

$$\frac{\partial f}{\partial \mu} = -2 \sum_{i=1}^n x_i + 2n\mu = 0$$

Resolviendo para μ :

$$2n\mu = 2 \sum_{i=1}^n x_i$$

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

La segunda derivada (matriz Hessiana) es:

$$\frac{\partial^2 f}{\partial \mu^2} = 2nI$$

donde I es la matriz identidad $D \times D$. Como $n > 0$, esta matriz es definida positiva, confirmando que tenemos un mínimo global. $\square$

En otras palabras, esta Proposición 2.1.1 dice que es el punto que está *más cerca* en promedio a todos los puntos del conjunto. En este sentido, es el centroide de los puntos del conjunto A .

Definimos

$$\text{var}(A) = \frac{1}{|A|} \sum_{a \in A} \|a - \mu(A)\|^2$$

la varianza de los datos que geoméricamente mide qué tan dispersos están los puntos alrededor de su centro de masa (la media). En estadística, es importante distinguir dos contextos:

- Varianza poblacional: Si contamos con todos los datos de la población, la fórmula anterior con denominador $n = |A|$ describe exactamente la dispersión o varianza.
- Varianza muestral: Si solo tenemos una muestra de tamaño n y queremos estimar la varianza de la población de la cual proviene, la fórmula anterior tiende a subestimar la verdadera dispersión. Esto ocurre porque la media de la muestra se ajusta a los datos y *absorbe* parte de la variabilidad.

Para corregir este sesgo se utiliza la llamada *corrección de Bessel*, que consiste en dividir entre $n - 1$ en lugar de n :

$$\text{var}(A) = \frac{1}{n-1} \sum_{a \in A} \|a - \mu(A)\|^2.$$

De esta manera, $s^2(A)$ es un estimador insesgado de la varianza poblacional. Intuitivamente, el factor $n - 1$ refleja que ya se ha “gastado” un grado de libertad al calcular la media, por lo que quedan $n - 1$ grados de libertad para medir la variación.

Desde un punto de vista geométrico, los vectores centrados $\{a - \text{mean}(A)\}_{a \in A}$ no son linealmente independientes, estos se encuentran en el subespacio afín de dimensión $n - 1$ definido por la condición

$$\sum_{a \in A} (a - \mu(A)) = 0.$$

Es precisamente esta restricción la que explica por qué, al estimar la varianza, la normalización natural es por $n - 1$ y no por n .

La correlación entre dos conjuntos $B_1, B_2 \subset \mathbb{R}$ tales que $|B_1| = |B_2| = n$ y $B_i = \{b_i^{(1)}, \dots, b_i^{(n)}\}$ cuantifica que tanto crecen o decrecen al mismo tiempo las coordenadas $(b_1^{(j)}, b_2^{(j)})$. Está dada por

$$\text{cov}(B_1, B_2) = \frac{1}{N-1} \sum_{i=1}^n (b_i^{(1)} - \mu(B_1))(b_i^{(2)} - \mu(B_2)).$$

Si denotamos $A = \{x_1, \dots, x_N\}$ y $x_i = (x_i^{(1)}, \dots, x_i^{(D)})$ y consideramos los vectores x_j como vectores columna, entonces la matriz de covarianza de A está dada por

$$\text{cov}(A) = \frac{1}{N-1} \sum_{k=1}^N (x_k - \mu(A))(x_k - \mu(A))^T \in \mathcal{M}_{D \times D}(\mathbb{R}). \quad (2.5)$$

Es decir,

$$\begin{aligned} \text{cov}(A) &= \frac{1}{N-1} \begin{pmatrix} \sum_{k=1}^N (x_k^1 - \mu_N^1)^2 & \cdots & \sum_{k=1}^N (x_k^1 - \mu_N^1)(x_k^D - \mu_N^D) \\ \sum_{k=1}^N (x_k^2 - \mu_N^2)(x_k^1 - \mu_N^1) & \cdots & \sum_{k=1}^N (x_k^2 - \mu_N^2)(x_k^D - \mu_N^D) \\ \vdots & \ddots & \vdots \\ \frac{1}{N} \sum_{k=1}^N (x_k^D - \mu_N^D)(x_k^1 - \mu_N^1) & \cdots & \sum_{k=1}^N (x_k^D - \mu_N^D)^2 \end{pmatrix} \\ &= \begin{pmatrix} \text{Var}(A^{(1)}) & \cdots & \text{cov}(A^{(1)}, A^{(D)}) \\ \text{cov}(A^{(2)}, A^{(1)}) & \cdots & \text{cov}(A^{(2)}, A^{(D)}) \\ \vdots & \ddots & \vdots \\ \text{cov}(A^{(D)}, A^{(1)}) & \cdots & \text{Var}(A^{(D)}) \end{pmatrix} \end{aligned}$$

donde $A^{(j)} = \{x_1^{(j)}, \dots, x_N^{(j)}\}$ son las j -simas coordenadas de los puntos en A . Observar que $\text{cov}(A)$ es una matriz simétrica y por lo tanto, sus eigenvalores son reales y los podemos ordenar como

$$\lambda_{\text{máx}} = \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n = \lambda_{\text{mín}}. \quad (2.6)$$

En la figura 2.1 podemos ver ejemplos de conjuntos en $\mathbb{R}^2$ junto con su covarianza.

Un concepto relacionado a la covarianza es la correlación, concretamente el coeficiente de correlación de Pearson.

Definición 2.1.2. Para dos conjuntos de datos $B = \{b_1, b_2, \dots, b_n\}$ y $C = \{c_1, c_2, \dots, c_n\}$, el coeficiente de correlación de Pearson se define como:

$$\text{corr}(B, C) = \frac{\sum_{i=1}^n (b_i - \mu(B))(c_i - \mu(C))}{\sqrt{\sum_{i=1}^n (b_i - \mu(B))^2} \sqrt{\sum_{i=1}^n (c_i - \mu(C))^2}}$$




Figura 2.1: Varios conjuntos de datos en $\mathbb{R}^2$ junto con su covarianza

Definición 2.1.3. Dado un conjunto de datos $A = \{x_1, x_2, \dots, x_N\}$, la matriz de correlación $\text{corr}(A)$ se define como:

$$\text{corr}(A) = \begin{bmatrix} r_{X_1 X_1} & r_{X_1 X_2} & \cdots & r_{X_1 X_p} \\ r_{X_2 X_1} & r_{X_2 X_2} & \cdots & r_{X_2 X_p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{X_p X_1} & r_{X_p X_2} & \cdots & r_{X_p X_p} \end{bmatrix}$$

2.2. Transformaciones de preprocesamiento

Definición 2.2.1. Sea $B = \{b_1, \dots, b_n\} \subset \mathbb{R}$ con $n > 1$, sea $\min_B \in B$ (resp. $\max_B \in B$) tal que $\min_B \leq b$ (resp. $\max_B \geq b$) para cualquier $b \in B$.

Definimos $f_B : \mathbb{R} \rightarrow [0, 1]$ dada por

$$f_B(a) = \frac{a - \min_B}{\max_B - \min_B}.$$

Sea $A = \{x_1, \dots, x_N\} \subset \mathbb{R}^D$ un conjunto de datos. Denotemos $x = (x^{(1)}, \dots, x^{(D)})$. Sea $F : \mathbb{R}^D \rightarrow \mathbb{R}^D$ dada por

$$F(x) = (f_{B_1}(x^{(1)}), \dots, f_{B_D}(x^{(D)})),$$

donde

$$B_k = \{x_1^{(k)}, \dots, x_N^{(k)}\}$$

son las coordenadas k -simas del conjunto de datos A . Llamamos a F un reescalamiento **min-max**.

Definición 2.2.2. Sea $B = \{b_1, \dots, b_n\} \subset \mathbb{R}$, sean $\mu(B)$ y $\sigma(B)$ la media aritmética y la desviación estandar de B respectivamente. Definimos $g_B : \mathbb{R} \rightarrow \mathbb{R}$ dada por

$$g(a) = \frac{a - \mu(B)}{\sigma(B)},$$

siempre que $\sigma(B) \neq 0$. Sea $A = \{x_1, \dots, x_N\} \subset \mathbb{R}^D$ un conjunto de datos. Denotemos $x = (x^{(1)}, \dots, x^{(D)})$. Sea $G : \mathbb{R}^D \rightarrow \mathbb{R}^D$ dada por

$$G(x) = (g_{B_1}(x^{(1)}), \dots, g_{B_D}(x^{(D)})),$$

donde

$$B_k = \{x_1^{(k)}, \dots, x_N^{(k)}\}$$

son las coordenadas k -simas del conjunto de datos A . Llamamos a G **normalización z-score**.

Proposición 2.2.3. Las transformaciones de las definiciones 2.2.1 y 2.2.2 son homeomorfismos y, en general, no son isometrías en A .

La siguiente proposición describe cómo distorsiona las distancias euclidianas las transformaciones de las definiciones 2.2.1 y 2.2.2.

Proposición 2.2.4. Sea $F : \mathbb{R}^D \rightarrow \mathbb{R}^D$ la transformación definida por $F(x) = (f_1(x_1), \dots, f_D(x_D))$, donde $f_i(x) = a_i x + b_i$ para $i = 1, \dots, D$ con $a_i \neq 0$. Sean $x, y \in \mathbb{R}^D$ y sea $d(\cdot, \cdot)$ la distancia euclidiana. Entonces:

$$\min_{1 \leq i \leq D} |a_i| \cdot d(x, y) \leq d(F(x), F(y)) \leq \max_{1 \leq i \leq D} |a_i| \cdot d(x, y)$$

Demostración. Primero calculamos la distancia transformada. Tenemos:

$$F(x) - F(y) = (f_1(x_1) - f_1(y_1), \dots, f_D(x_D) - f_D(y_D)) \quad (2.7)$$

$$= (a_1(x_1 - y_1), \dots, a_D(x_D - y_D)) \quad (2.8)$$

Por tanto:

$$d(F(x), F(y))^2 = \|F(x) - F(y)\|^2 \quad (2.9)$$

$$= \sum_{i=1}^D (a_i(x_i - y_i))^2 \quad (2.10)$$

$$= \sum_{i=1}^D a_i^2(x_i - y_i)^2 \quad (2.11)$$

Sea $\alpha = \min_{1 \leq i \leq D} |a_i|$ y $\beta = \max_{1 \leq i \leq D} |a_i|$.

Para la cota inferior, como $a_i^2 = |a_i|^2 \geq \alpha^2$ para todo i :

$$\sum_{i=1}^D a_i^2(x_i - y_i)^2 \geq \sum_{i=1}^D \alpha^2(x_i - y_i)^2 \quad (2.12)$$

$$= \alpha^2 \sum_{i=1}^D (x_i - y_i)^2 \quad (2.13)$$

$$= \alpha^2 d(x, y)^2 \quad (2.14)$$

Para la cota superior, como $a_i^2 = |a_i|^2 \leq \beta^2$ para todo i :

$$\sum_{i=1}^D a_i^2(x_i - y_i)^2 \leq \sum_{i=1}^D \beta^2(x_i - y_i)^2 \quad (2.15)$$

$$= \beta^2 \sum_{i=1}^D (x_i - y_i)^2 \quad (2.16)$$

$$= \beta^2 d(x, y)^2 \quad (2.17)$$

Combinando ambas desigualdades,

$$\alpha^2 d(x, y)^2 \leq d(F(x), F(y))^2 \leq \beta^2 d(x, y)^2.$$

Tomando raíz cuadrada (todas las cantidades son no-negativas) tenemos

$$\alpha \cdot d(x, y) \leq d(F(x), F(y)) \leq \beta \cdot d(x, y)$$

lo cual demuestra la proposición. $\square$

Definición 2.2.5. Sea $A = \{x_1, \dots, x_N\} \subset \mathbb{R}^D$ un conjunto de datos. Definimos la función $H : \mathbb{R}^D \rightarrow S^{D-1}$ dada por

$$H(x) = \frac{1}{\|x\|_p} x$$

Donde $\|\cdot\|_p$ denota la p -norma de Minkowski. Llamamos a H la **normalización unitaria**.

Observación 2.2.6. ...

Ejercicios

1. Encuentra una transformación similar a la transformación min-max pero cuya imagen en cada coordenada sea el intervalo $[a, b]$ para algunos a, b dados.
2. ...

2.3. Maldición de la dimensionalidad

La maldición de la dimensionalidad es un fenómeno fundamental que emerge cuando trabajamos con espacios de alta dimensión, donde las intuiciones geométricas desarrolladas en dimensiones bajas fallan. Conforme aumenta la dimensión del espacio, las distancias entre puntos tienden a volverse uniformemente grandes, los volúmenes se concentran en las esquinas de los hipercubos, y los algoritmos que dependen de nociones de proximidad pierden su eficacia. Este comportamiento contraintuitivo no es meramente una curiosidad matemática, sino que plantea desafíos profundos en áreas como el análisis de datos, la optimización, y el aprendizaje automático, donde frecuentemente debemos trabajar con espacios de dimensión exponencialmente grande. La comprensión rigurosa de estos fenómenos requiere herramientas de la teoría de la medida, probabilidad en espacios de alta dimensión, y geometría convexa, revelando conexiones entre la combinatoria, el análisis funcional y la geometría diferencial.

Hinneburg et al. [2000], Ball et al. [1997] ...

Proposición 2.3.1. *Sea C el hipercubo $[-1, 1]^D \subset \mathbb{R}^D$. El radio de la bola más grande se puede inscribir en C es 1. El radio de la bola más pequeña que circunscribe a C es $\sqrt{D}$.*

La proposición anterior nos dice que, conforme crece la dimensión D , el hipercubo se parece menos a una bola en el sentido de que el volumen se empieza a acumular en las esquinas. La siguiente proposición nos da más evidencia al respecto.

Proposición 2.3.2. *Sea $D \in \mathbb{N}$ y consideremos 2^D esferas de radio 1 en $\mathbb{R}^D$ cuyos centros son los puntos $(\pm 1, \dots, \pm 1)$. Sea r el radio de la esfera centrada en el origen y tangente a todas las esferas de radio 1. Para D suficientemente grande r es más grande que el lado del hipercubo que contiene a las esferas, es decir, $r > 4$.*

Demostración. Sea S la hiperesfera centrada en el origen y tangente a todas las esferas de radio 1. La distancia del centro de S al centro de cualquiera de los centros ... es $\sqrt{D}$, por lo tanto, el radio de S es

$$r = \sqrt{D} - 1$$

Para D suficientemente grande (concretamente $D > 25$), $r > 4$. □

Proposición 2.3.3 (Concentración de distancias). ... reformulando ...

Demostración. ... □

Proposición 2.3.4. *Para puntos en la esfera unitaria S^{d-1} , las distancias se concentran alrededor de $\sqrt{2}$... es cierto?*

Demostración. **Paso 1: Distancia entre puntos en la esfera** Para $x, y \in S^{d-1}$, tenemos $\|x\| = \|y\| = 1$, por tanto:

$$\|x - y\|^2 = \|x\|^2 + \|y\|^2 - 2\langle x, y \rangle = 2 - 2\langle x, y \rangle = 2(1 - \cos \theta)$$

donde θ es el ángulo entre x e y .

Paso 2: Concentración del producto escalar Para puntos "típicos" en S^{d-1} , el producto escalar $\langle x, y \rangle$ se concentra cerca de 0.

Consideremos la función $f(x) = \langle x, v \rangle$ para v fijo en S^{d-1} . Esta función tiene gradiente $\nabla f(x) = v$, por tanto $\|\nabla f\|_\infty = 1$.

Por el lema de concentración en la esfera (versión determinística): Para cualquier $\epsilon > 0$, la fracción de puntos $x \in S^{d-1}$ tales que $|\langle x, v \rangle| > \epsilon$ es a lo más:

$$2 \exp\left(-\frac{d\epsilon^2}{8}\right)$$

Paso 3: Implicación para distancias Si $|\langle x, y \rangle| \leq \epsilon$, entonces:

$$\sqrt{2(1-\epsilon)} \leq \|x - y\| \leq \sqrt{2(1+\epsilon)}$$

Para $\epsilon = \sqrt{\frac{8 \log n}{d}}$, una fracción $1 - \frac{2}{n^2}$ de los pares de puntos satisface:

$$\frac{\|x - y\|_{\text{máx}} - \|x - y\|_{\text{mín}}}{\|x - y\|_{\text{mín}}} \leq \frac{\sqrt{2(1+\epsilon)} - \sqrt{2(1-\epsilon)}}{\sqrt{2(1-\epsilon)}} = O\left(\sqrt{\frac{\log n}{d}}\right)$$

□

Corolario 2.3.5 (Interpretación geométrica). *En dimensión alta, la mayoría de los puntos de cualquier conjunto finito están aproximadamente a la misma distancia unos de otros, independientemente de su distribución específica.*




Figura 2.2: La maldición de la dimensionalidad

Ejercicios

1. Definir N puntos en $\mathbb{R}^D$ y comparar las distancias...

2. ¿Por qué las distancias euclidianas crecen?
3. Sea $V_D(r)$ el volumen de una bola cerrada de radio r en $\mathbb{R}^D$. Demuestre que, para un radio fijo $r < 1$, el volumen tiende a cero cuando la dimensión tiende a infinito:

$$\lim_{D \rightarrow \infty} V_D(r) = 0$$

para $r < 1$.

2.4. Proyecciones Isométricas

El lema de Johnson-Lindenstrauss estudia la distorsión de distancias en conjuntos de puntos en proyecciones sobre dimensiones inferiores [Johnson et al. \[1984\]](#).

Definición 2.4.1. Sea d la métrica euclidiana en $\mathbb{R}^D$. Para un subconjunto finito $A \subset \mathbb{R}^D$ decimos que $f : \mathbb{R}^D \rightarrow \mathbb{R}^n$ es una isometría en A si

$$d(a, b) = d(f(a), f(b))$$

para cualesquiera $a, b \in A$. Por otro lado, decimos que $f : \mathbb{R}^D \rightarrow \mathbb{R}^n$ es una ε -isometría en A si

$$(1 - \varepsilon)d(a, b) \leq d(f(a), f(b)) \leq (1 + \varepsilon)d(a, b).$$

Teorema 2.4.2. Sea $A \subset \mathbb{R}^D$ con $|A| = n$ y $n < D$, entonces existe $F : \mathbb{R}^D \rightarrow \mathbb{R}^n$ tal que F es una isometría en A .

Demostración. Denotemos $A = \{a_1, \dots, a_n\}$ y hacemos

$$A_0 = \{a_2 - a_1, \dots, a_n - a_1\},$$

es decir, trasladamos los puntos de manera que a_1 coincida con el origen. Sea $S = \langle A_0 \rangle \subset \mathbb{R}^D$ el subespacio vectorial generado por A_0 , observar que $k := \dim(S) \leq n - 1$ dependiendo de si los elementos de A_0 son linealmente independientes (es decir, si los puntos A son linealmente independientes, interpretación? algo de posición general?).

Sea $\{v_1, \dots, v_k\}$ una base ortonormal de S^1 . Completamos para que sea una base ortonormal de R^D , $\{v_1, \dots, v_k, v_{k+1}, \dots, v_D\}$. Definamos $f : \mathbb{R}^D \rightarrow \mathbb{R}^k$ dada por

$$f(x) = (\langle x - a_1, v_1 \rangle, \dots, \langle x - a_1, v_k \rangle, 0, \dots, 0).$$

Veamos que f es una isometría en A . Sean $a_i, a_j \in A$, notemos primero que

$$\begin{aligned} \|\text{Proj}_S(a_j - a_i)\|^2 &= \left\| \sum_{l=1}^k \frac{\langle a_i - a_j, v_l \rangle}{\langle v_l, v_l \rangle} v_l \right\|^2 \\ &= \left\| \sum_{l=1}^k \langle a_i - a_j, v_l \rangle v_l \right\|^2 \\ &= \left\langle \sum_{l=1}^k \langle a_i - a_j, v_l \rangle v_l, \sum_{l=1}^k \langle a_i - a_j, v_l \rangle v_l \right\rangle \quad (2.18) \\ &= \sum_{l=1}^k \sum_{m=1}^k \langle a_i - a_j, v_l \rangle \langle a_i - a_j, v_m \rangle \langle v_l, v_m \rangle \\ &= \sum_{l=1}^k \langle a_i - a_j, v_l \rangle^2. \end{aligned}$$

Por otro lado, $a_i - a_j \in S$ ya que

$$a_i - a_j = (a_i - a_1) + (-1)(a_j - a_1).$$

Entonces, $\text{Proj}_S(a_j - a_i) = a_j - a_i$. De esto, y de (2.18), tenemos

$$\begin{aligned} \|f(a_i) - f(a_j)\|^2 &= \|(\langle a_i - a_1, v_1 \rangle - \langle a_j - a_1, v_1 \rangle, \dots, \langle a_i - a_1, v_k \rangle - \langle a_j - a_1, v_k \rangle, 0, \dots, 0)\|^2 \\ &= \|(\langle a_i - a_j, v_1 \rangle, \dots, \langle a_i - a_j, v_k \rangle, 0, \dots, 0)\|^2 \\ &= \sum_{l=1}^k \langle a_i - a_j, v_l \rangle^2 \\ &= \|\text{Proj}_S(a_j - a_i)\|^2 \\ &= \|a_i - a_j\|^2. \end{aligned}$$

Es decir, f es una isometría en A . □

¹No es única...

Este teorema anterior nos dice que

¿Podemos disminuir la dimensión y seguir preservando las distancias entre puntos de A ?

Teorema 2.4.3 (Lema de Johnson-Lindenstrauss). *Sea $\varepsilon \in (0, 1)$ y $n \in \mathbb{N}$, sea k tal que*

$$k \geq \frac{4}{\frac{1}{2}\varepsilon^2 - \frac{1}{3}\varepsilon^3} \log(n)$$

Entonces, para cada $X \subset \mathbb{R}^D$ con $|X| = n$, existe transformación lineal $f : \mathbb{R}^D \rightarrow \mathbb{R}^k$ que es una ε -isometría para X .

Teorema 2.4.4. *Sea $\varepsilon \in (0, 1)$, $\tau > 1$ y $n \in \mathbb{N}$, sea k tal que*

$$k \geq \frac{2 + \tau}{\frac{1}{2}\varepsilon^2 - \frac{1}{3}\varepsilon^3} \log(n).$$

Entonces, para cualquier conjunto X de n puntos en $\mathbb{R}^D$, tomamos $f : \mathbb{R}^D \rightarrow \mathbb{R}^k$ como una proyección adecuadamente escalada sobre un subespacio aleatorio de dimensión k , entonces f es una ε -isometría para X con probabilidad al menos $1 - \frac{1}{n^\tau}$.

Podemos interpretar el Teorema 2.4.4 de la siguiente forma. Se nos proporciona un conjunto de datos de alta dimensión de manera secuencial, un dato a la vez. Para ejecutar una técnica de reducción de dimensionalidad como PCA, necesitaríamos esperar hasta recibir el último punto de datos y luego calcular el mapa de reducción de dimensionalidad. Usando el Teorema 2.4.4 puedes elegir una proyección al azar al inicio del proceso (sólo necesitamos saber una estimación del logaritmo del tamaño del conjunto de datos) y transformar cada punto usando esta proyección. Este teorema nos asegura que este procedimiento no distorsionará los datos en más de ε con alta probabilidad.

Ejercicios

- Consideremos el siguiente ejemplo de datos en $\mathbb{R}^3$... Realiza una proyección isométrica en ...

2.5. Análisis de Componentes Principales

El Análisis de Componentes Principales (PCA, por sus siglas en inglés) es un método matemático que utiliza álgebra lineal para proyectar datos de alta dimensionalidad a un espacio de menor dimensión, preservando la máxima varianza posible de los datos originales. Esta técnica se basa en la descomposición espectral de la matriz de covarianza para encontrar las direcciones (componentes principales) en las que los datos presentan mayor variabilidad. Es decir, se basa en la búsqueda de direcciones ortogonales que expliquen tanta varianza de los datos como sea posible.

PCA se utiliza principalmente para la reducción de dimensionalidad, visualización de datos complejos, eliminación de ruido, y como paso de preprocesamiento en algoritmos de aprendizaje automático para mejorar la eficiencia computacional y evitar la maldición de la dimensionalidad. El método fue introducido por Karl Pearson en 1901 [Pearson \[1901\]](#) y posteriormente desarrollado por Harold Hotelling en 1933 [Hotelling \[1933\]](#), quien formalizó el procedimiento matemático que conocemos hoy en día.

Consideremos dos posibles objetivos para escoger una buena proyección $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$:

- P1** Encontrar el subespacio afín d -dimensional para el cual las proyecciones de $\mathbf{x}_1, \dots, \mathbf{x}_n$ aproximen los puntos originales $\mathbf{x}_1, \dots, \mathbf{x}_n$.
- P2** Encontrar la proyección d -dimensional de $\mathbf{x}_1, \dots, \mathbf{x}_n$ que preserve la mayor cantidad posible de la varianza de los datos.

2.5.1. PCA como problema de optimización

Resolvamos el problema **P1** descrito en la subsección anterior. Recordemos que $A \subset \mathbb{R}^D$ es un conjunto finito de N puntos y sea $d < D$. Consideraremos a todos los vectores $w \in \mathbb{R}^D$ como vectores columna $w \in \mathcal{M}_{D \times 1}(\mathbb{R})$ en los siguientes cálculos.

Queremos aproximar cada punto $x_k \in A$ como

$$x_k \approx \mu + \sum_{j=1}^d \beta_k^{(j)} v_j \quad (2.19)$$

donde $v_1, \dots, v_d \in \mathbb{R}^D$ es una base ortonormal de un subespacio d -dimensional

de $\mathbb{R}^D$ y $\mu \in \mathbb{R}^D$ es una traslación. Además, $\beta_k = (\beta_k^{(1)}, \dots, \beta_k^{(d)}) \in \mathbb{R}^d$ son los coeficientes del punto en $\langle v_1, \dots, v_d \rangle$ que mejor aproxima a $x_k - \mu$.

Sea $V = (v_1, \dots, v_d) \in \mathcal{M}_{D \times d}(\mathbb{R})$ la matriz de la base de vectores columna ortonormales, por lo tanto $V^T V = Id \in \mathcal{M}_{d \times d}(\mathbb{R})$. Podemos reescribir (2.19) como

$$x_k \approx \mu + V\beta_k^T. \quad (2.20)$$

Cuantificamos la calidad de la aproximación usando la norma usual

$$e = \sum_{k=1}^N \|x_k - (\mu + V\beta_k^T)\|^2$$

Entonces encontrar $\mu, V, \beta_1, \dots, \beta_N$ de tal manera que e sea mínimo es resolver el problema de optimización

$$\min_{\substack{\mu, V, \beta_k \\ V^T V = Id}} \sum_{k=1}^N \|x_k - (\mu + V\beta_k^T)\|^2 \quad (2.21)$$

Podemos optimizar secuencialmente para cada una de las variables μ, β_k, V (ver [Boyd and Vandenberghe, 2004, Sección 4.1.3]). Comencemos con μ , observemos que, para cualquier $k = 1, \dots, N$ tenemos,

$$\begin{aligned} \|x_k - \mu - V\beta_k\|^2 &= (x_k - \mu - V\beta_k)^T (x_k - \mu - V\beta_k) \\ &= (x_k - \mu - V\beta_k)^T x_k - (x_k - \mu - V\beta_k)^T \mu \\ &\quad - (x_k - \mu - V\beta_k)^T V\beta_k \\ &= x_k^T x_k - \mu^T x_k - (V\beta_k)^T x_k - x_k^T \mu + \mu^T \mu + (V\beta_k)^T \mu \\ &\quad - x_k^T V\beta_k + \mu^T V\beta_k + (V\beta_k)^T V\beta_k \\ &= x_k^T x_k - 2\mu^T x_k - 2(V\beta_k)^T x_k + \mu^T \mu + 2\mu^T V\beta_k \\ &\quad + (V\beta_k)^T V\beta_k. \end{aligned}$$

Derivamos respecto a μ tenemos, para cada k ,

$$\nabla_{\mu} \|x_k - \mu - V\beta_k\|^2 = -2x_k + 2\mu + 2V\beta_k^T$$

y por lo tanto,

$$\nabla_{\mu} \sum_{k=1}^n \|x_k - \mu - V\beta_k\|_2^2 = -2 \sum_{k=1}^n (x_k - \mu - V\beta_k^T).$$

Como una condición necesaria para que μ sea optimo es que $\nabla_{\mu} = 0$ [Boyd and Vandenberghe, 2004, Capítulo 9.1], tenemos

$$\begin{aligned} \nabla_{\mu} \sum_{k=1}^N \|x_k - (\mu + V\beta_k^T)\|^2 = 0 &\Leftrightarrow \sum_{k=1}^N (x_k - \mu - V\beta_k^T) = 0 \\ &\Leftrightarrow \sum_{k=1}^N (x_k) - N\mu - V \sum_{k=1}^N (\beta_k^T) = 0 \end{aligned}$$

y luego,

$$\mu = \frac{1}{N} \sum_{k=1}^N (x_k - V\beta_k^T). \quad (2.22)$$

Podemos suponer que $\sum_{k=1}^N \beta_k = 0$. Para esto, hacemos el cambio de variable $\tilde{\beta}_k = \beta_k - \frac{1}{N} \sum_{j=1}^N \beta_j$ y luego,

$$\sum_{k=1}^N \tilde{\beta}_k = \sum_{k=1}^N \left(\beta_k - \frac{1}{N} \sum_{j=1}^N \beta_j \right) = \sum_{k=1}^N \beta_k - \sum_{j=1}^N \beta_j = 0.$$

Sustituyendo en (2.22) tenemos

$$\begin{aligned} \mu &= \frac{1}{N} \sum_{k=1}^N (x_k - V\beta_k^T) \\ &= \frac{1}{N} \left(\sum_{k=1}^N x_k - V \sum_{k=1}^N \beta_k^T \right) \\ &= \frac{1}{N} \sum_{k=1}^N x_k = \mu(A). \end{aligned}$$

Por lo tanto, el problema original (2.21) se convierte en

$$\min_{\substack{V, \beta_k \\ V^T V = \text{Id}}} \sum_{k=1}^N \|(x_k - \mu(A)) + V\beta_k^T\|^2$$

Este mínimo se alcanza cuando β_k es la proyección de $x_k - \mu(A)$ en el espacio generado por las columnas de V . Esto quiere decir que

$$\beta_k = V^T(x_k - \mu(A)),$$

entonces la función a optimizar es

$$\min_{\substack{V \\ VV^T = \text{Id}}} \sum_{k=1}^N \|(x_k - \mu(A)) + VV^T(x_k - \mu(A))\|^2$$

Desarrollando con $\|z\|^2 = z \cdot z^T$ y simplificando tenemos el problema de optimización

$$\min_{\substack{V \\ V^T V = \text{Id}}} \sum_{k=1}^N ((x_k - \mu(A))^T(x_k - \mu(A)) - (x_k - \mu(A))^T V V^T (x_k - \mu(A)))$$

o equivalentemente,

$$\max_{\substack{V \\ V^T V = \text{Id}}} \sum_{k=1}^N (x_k - \mu(A))^T V V^T (x_k - \mu(A)).$$

Dado que $(x_k - \mu(A))^T V V^T (x_k - \mu(A)) \in \mathbb{R}$, y usando la propiedad cíclica de la traza, tenemos

$$\begin{aligned}
\sum_{k=1}^N (x_k - \mu(A))^T V V^T (x_k - \mu(A)) &= \sum_{k=1}^N \text{Tr}((x_k - \mu(A))^T V V^T (x_k - \mu(A))) \\
&= \sum_{k=1}^N \text{Tr}(V^T (x_k - \mu(A)) (x_k - \mu(A))^T V) \\
&= \text{Tr}\left(V^T \sum_{k=1}^N (x_k - \mu(A)) (x_k - \mu(A))^T V\right) \\
&= (N-1) \text{Tr}(V^T \text{Cov}(A) V) \quad (2.23)
\end{aligned}$$

Entonces el problema de optimización se convierte en

$$\max_{\substack{V \\ V^T V = \text{Id}}} \text{Tr}(V^T \text{Cov}(A) V)$$

Por el Corolario al Teorema de Fan (Corolario 2.5.2) tenemos que la solución está dada por $V = \{v_1, \dots, v_d\}$ donde v_i es el i -simo vector propio unitario de $\text{Cov}(A)$ ordenados como en (2.6).

Teorema 2.5.1 (Ky Fan, 1949). *Sea $H \in \mathbb{C}^{n \times n}$ una matriz Hermitiana con valores propios*

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n.$$

Para cualquier entero positivo $q < n$, las sumas

$$\sum_{i=1}^q \lambda_i \quad \text{y} \quad \sum_{i=n-q+1}^n \lambda_i$$

son, respectivamente, el valor máximo y el valor mínimo de

$$\sum_{j=1}^q \langle H x_j, x_j \rangle,$$

donde $x_1, \dots, x_q$ son sistemas de q vectores ortonormales en el espacio.

Demostración. Ver Teorema 1 de Fan [1949]. También se puede ver como una generalización del Teorema 2.5.3. $\square$

Corolario 2.5.2. Sea $A \in \mathcal{M}_{N \times D}(\mathbb{R})$ un conjunto de datos y sea $\text{cov}(A) \in \mathcal{M}_{D \times D}(\mathbb{R})$ su matriz de covarianza con vectores propios reales

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n.$$

Sea $V \in \mathcal{M}_{D \times d}(\mathbb{R})$ una matriz de vectores columna ortonormales, es decir, $V^T V = \text{Id}$. Entonces el máximo de

$$\text{Tr}(V^T \text{Cov}(A) V)$$

es $\sum_{i=1}^d \lambda_i$ y se alcanza con la matriz V cuya i -ésima columna es el vector propio asociado a λ_i .

Demostración. Observar que, para $v_j \in \mathbb{R}^D$

$$\sum_{j=1}^d \langle H v_j, v_j \rangle = \sum_{j=1}^d v_j^T H v_j$$

y por lo tanto, si tenemos d vectores $v_1, \dots, v_d \in \mathbb{R}^D$ agrupados en una matriz $V \in \mathcal{M}_{D \times d}(\mathbb{R})$, entonces

$$\sum_{j=1}^d \langle H v_j, v_j \rangle = \text{Tr}(V^T H V).$$

Aplicando el Teorema 2.5.1 a esta expresión con $q = d$, $n = D$ y $H = \text{Cov}(A)$ tenemos la conclusión. $\square$

Teorema 2.5.3 (Teorema de Rayleigh-Ritz). Let $A \in \mathbb{C}^{n \times n}$ be a Hermitian matrix. Then its eigenvectors are the critical points (vectors) of the emph-Rayleigh quotient, which is the real function $R : \mathbb{C}^n \setminus \{0\} \rightarrow \mathbb{R}$

$$R(x) = \frac{x^H A x}{x^H x}, \quad \|x\| \neq 0$$

and its eigenvalues are its values at such critical points.

As a consequence, we have:

$$\lambda_{\max} = \max_{\|x\| \neq 0} \frac{x^H A x}{x^H x}$$

and

$$\lambda_{\min} = \min_{\|x\| \neq 0} \frac{x^H A x}{x^H x}$$

Demostración. Ver Teorema 4.2.2 de [Horn and Johnson \[2012\]](#). $\square$

2.5.2. La relación con la varianza

Ahora resolvamos el siguiente problema **P2** y veremos que es equivalente al problema **P1**. Otra vez, sea $A = \{x_1, \dots, x_N\} \subset \mathbb{R}^D$ un conjunto finito de N puntos y sea $d < D$. Buscamos una base ortonormal representada por la matriz de vectores columna $V \in \mathcal{M}_{D \times d}(\mathbb{R})$ de tal forma que la proyección de los puntos $x_k - \mu(A)$ maximicen la varianza. Es decir, queremos resolver el problema

$$\max_{\substack{V \\ V^T V = \text{Id}}} \sum_{k=1}^N \|V^T(x_k - \mu(A)) - \frac{1}{N} \sum_{j=1}^N V^T(x_j - \mu(A))\|^2.$$

Observemos que

$$\begin{aligned} \frac{1}{N} \sum_{j=1}^N V^T(x_j - \mu(A)) &= \frac{1}{N} V^T \sum_{j=1}^N (x_j - \mu(A)) \\ &= V^T \left(\frac{1}{N} \sum_{j=1}^N x_j - \frac{1}{N} \sum_{j=1}^N \mu(A) \right) \\ &= V^T (\mu(A) - \mu(A)) = 0 \end{aligned}$$

Por lo tanto, el problema se transforma en

$$\max_{\substack{V \\ V^T V = \text{Id}}} \sum_{k=1}^N \|V^T(x_k - \mu(A))\|^2.$$

Dado que

$$\begin{aligned}
\sum_{k=1}^N \|V^T(x_k - \mu(A))\|^2 &= \sum_{k=1}^N (V^T(x_k - \mu(A)))^T (V^T(x_k - \mu(A))) \\
&= \sum_{k=1}^N (x_k - \mu(A)) V V^T (x_k - \mu(A)) \\
&= (N - 1) \text{Tr} (V^T \text{Cov}(A) V)
\end{aligned}$$

Esto último por el mismo argumento que (2.23). Entonces el problema de maximizar la varianza es equivalente a

$$\max_{\substack{V \\ V^T V = \text{Id}}} \text{Tr} (V^T \text{Cov}(A) V).$$

El cual es equivalente a **P1**.

2.5.3. Implementación computacional

Recapitulamos la solución al problema de optimización resuelto en la sección 2.5.1 para describir el proceso de encontrar las componentes principales y realizar la reducción de dimensionalidad en un conjunto de datos. Comenzamos entonces con un conjunto de datos $A \in \mathcal{M}_{N \times D}(\mathbb{R})$, centramos los datos situando su centroide en el origen haciendo $A - \text{mean}(A)$, abusando la notación, llamamos otra vez A al resultado de la traslación.

Ahora, calculamos la matriz de covarianza, usando (2.5),

$$\text{cov}(A) = \frac{1}{N - 1} \sum_{k=1}^N (x_k - \mu(A))(x_k - \mu(A))^T \in \mathcal{M}_{D \times D}(\mathbb{R}).$$

Es una matriz simétrica y por lo tanto todos sus eigenvalores son reales. Diagonalizamos esta matriz, es decir, encontramos $P \in \mathcal{M}_{D \times D}(\mathbb{R})$, $\Delta \in \mathcal{M}_{D \times D}(\mathbb{R})$ tales que

$$\Delta = P^T \cdot \text{cov}(A) \cdot P,$$

donde P es la matriz de eigenvectores columna de $\text{cov}(A)$ con norma 1. Consideremos $d < D$, definimos la matriz $P_d \in \mathcal{M}_{d \times D}(\mathbb{R})$ cuyas columnas son los d eigenvectores mayores de $\text{cov}(A)$ (ordenados como en 2.6). Entonces

$$A_r = (V^T A)^T \in \mathcal{M}_{N \times d}(\mathbb{R})$$

es la reducción de dimensionalidad de A . Es decir, A_r representa al conjunto de N puntos en $\mathbb{R}^d$.

Usaremos la implementación de PCA de scikit-learn [PCA](#). En la notebook ... se pueden consultar varios ejemplos ilustrando algunos de los conceptos más importantes desarrollados y usados en la sección [2.5.1](#).

Ejercicios

1. Obten un conjunto de datos que se encuentren dentro de la cerradura de un elipsoide en $\mathbb{R}^3$ con ejes de longitudes $\frac{1}{3}$, 1 y 5.
 - a) Calcula la reducción de dimensionalidad PCA con $d = 2$.
 - b) Grafica el conjunto resultante.
 - c) Escoge 3 puntos y mide sus distancias antes y después de la proyección.

Repite el mismo ejercicio con un elipsoide en $\mathbb{R}^{20}$, puedes usar la definición de elipsoide en términos de matrices (ver por ejemplo la definición 4.12 de [Grötschel et al. \[2012\]](#)).

2. Demuestra el teorema de Rayleigh-Ritz para matrices reales: ...
3. Demuestra que si $H \in \mathcal{M}_{n \times n}(\mathbb{C})$ es una matriz Hermitiana entonces todos los eigenvalores de H son reales.
4. Supongamos que queremos proyectar un conjunto $A \subset \mathbb{R}^D$ en espacios d_1, d_2 dimensionales con $d_2 < d_1 < D$. En lugar de entrenar dos modelos de PCA para d_1 y d_2 respectivamente, basta con entrenar un modelo para d_1 para obtener la reducción A_{d_1} . Para encontrar la proyección a $\mathbb{R}^{d_2}$ basta con tomar las d_2 primeras columnas de la representación matricial de A_{d_1} .

2.6. UMAP

Este método fue introducido en 2018 [McInnes et al. \[2018\]](#)...

1. Singular Value Decomposition.
2. Filtraciones y complejos simpliciales

- **Herramientas:**

- UMAP (Uniform Manifold Approximation and Projection). Método no lineal de reducción de dimensionalidad basado en la preservación de la estructura topológica local y global de los datos, modelados como una variedad Riemanniana. Implementaciones a usar: `umap-learn`

- **Ejemplo:** Visualización 2D y 3D de datos MNIST en $\mathbb{R}^{784}$, y otros datasets clásicos.

Uniform Manifold Approximation and Projection: es un método de reducción de dimensiones que se puede utilizar para visualización de forma similar al [t-SNE](#), pero también para la reducción de dimensiones *no lineales*, en general (<https://umap-learn.readthedocs.io/en/latest/>). En otras palabras, UMAP reduce el número de dimensiones en conjuntos de datos a la vez que “preserva” la estructura local y global del conjunto, lo que facilita la visualización y comprensión de datos complejos y de alta dimensión.

El método se basa en tres hipótesis sobre los datos:

- Los datos se distribuyen uniformemente en una variedad riemanniana.
- La métrica riemanniana es localmente constante (o puede aproximarse como tal).
- La variedad es localmente conexa.

Capítulo 3

Explorando la Forma de los Datos

En este módulo nos planteamos la pregunta ¿Cómo caracterizamos la estructura topológica de conjuntos de datos? Esta caracterización puede hacerse de forma cuantitativamente y/o cualitativamente.

3.1. Homología Persistente

La Homología persistente es una herramienta topológica para cuantificar características topológicas globales (como agujeros, componentes conexas o cavidades) en datos de alta dimensión, capturando su persistencia a través de diferentes escalas.

Existen muchas formas de representar un espacio topológico, una de ellas es mediante una descomposición en piezas simples. Queremos que esta descomposición cumpla que las piezas sean topológicamente simples y sus intersecciones comunes sean piezas de menor dimensión del mismo tipo. Dentro de estos requisitos, aún hay gran libertad. Particularmente atractivas son las opciones extremas: pocas piezas complicadas o muchas piezas simples. La primera opción facilita los cálculos manuales de invariantes topológicos y el diseño de formas estéticamente agradables, como carrocerías de autos. La segunda opción es preferida en cómputo y automatización. Dado que nos enfocamos en los aspectos computacionales de la topología, favorecemos esta última opción, de la cual el **complejo simplicial** es el principal ejemplo.

Las referencias principales son [[Edelsbrunner and Harer, 2010](#), Capítulo

3], [Munkres, 2018, Capítulo 1].

3.1.1. Tipo de Homotopía

Definición 3.1.1. Decimos que dos espacios topológicos X e Y tienen el mismo **tipo de homotopía** si existen funciones continuas $f : X \rightarrow Y$ y $g : Y \rightarrow X$ tales que $f \circ g = id_Y$ y $g \circ f \simeq id_X$. En este caso, escribimos $X \simeq Y$.

Ejemplo 3.1.2. El cilindro $X = S^1 \times [0, 1]$ tiene el mismo tipo de homotopía que el círculo $Y = S^1$.

Definimos las funciones continuas $f : X \rightarrow Y$ y $g : Y \rightarrow X$

- La proyección al círculo base:

$$f(e^{i\theta}, t) = e^{i\theta}$$

- La inclusión en el nivel medio:

$$g(e^{i\theta}) = \left(e^{i\theta}, \frac{1}{2} \right)$$

Primero verificamos que $f \circ g = id_Y$:

$$(f \circ g)(e^{i\theta}) = f\left(e^{i\theta}, \frac{1}{2}\right) = e^{i\theta}$$

Por tanto, $f \circ g = id_Y$ exactamente.

Construimos la homotopía entre $g \circ f$ y id_X . Definimos $H : X \times [0, 1] \rightarrow X$ por:

$$H((e^{i\theta}, t), s) = \left(e^{i\theta}, (1-s)t + \frac{s}{2} \right)$$

Verificamos las condiciones de homotopía:

- H es continua (suma y producto de funciones continuas)
- $H((e^{i\theta}, t), 0) = (e^{i\theta}, t) = id_X(e^{i\theta}, t)$
- $H((e^{i\theta}, t), 1) = (e^{i\theta}, \frac{1}{2}) = (g \circ f)(e^{i\theta}, t)$

Por tanto, $g \circ f \simeq id_X$. Luego, como $f \circ g = id_Y$ y $g \circ f \simeq id_X$, los espacios X e Y tienen el mismo tipo de homotopía. $\square$

Ejemplo 3.1.3. El plano perforado $X = \mathbb{R}^2 \setminus \{0\}$ tiene el mismo tipo de homotopía que el círculo $Y = S^1$.

Identificamos $\mathbb{R}^2 \cong \mathbb{C}$ para simplificar la notación. Definimos:
La normalización (proyección radial):

$$f(v) = \frac{v}{\|v\|}$$

donde $\|v\|$ denota la norma euclídea. Notemos que $f(v) \in S^1$ por construcción.

La inclusión natural:

$$g(v) = v$$

Paso 1: Verificamos que $f \circ g = id_Y$: Para $v \in S^1$, tenemos $\|v\| = 1$, por tanto:

$$(f \circ g)(v) = f(v) = \frac{v}{\|v\|} = \frac{v}{1} = v$$

Así, $f \circ g = id_Y$ exactamente.

Paso 2: Construimos la homotopía entre $g \circ f$ y id_X . Definimos $H : X \times [0, 1] \rightarrow X$ por:

$$H(v, s) = (1 - s)v + s \frac{v}{\|v\|}$$

Verificación crucial: Debemos comprobar que $H(v, s) \neq 0$ para todo $(v, s) \in X \times [0, 1]$.

Escribimos $H(v, s)$ como:

$$H(v, s) = v \left((1 - s) + \frac{s}{\|v\|} \right) = v \cdot \lambda(v, s)$$

donde $\lambda(v, s) = (1 - s) + \frac{s}{\|v\|}$.

Como $v \neq 0$ (pues $v \in X$), bastaría ver que $\lambda(v, s) \neq 0$. Analizamos:

- Si $s = 0$: $\lambda(v, 0) = 1 > 0$
- Si $s = 1$: $\lambda(v, 1) = \frac{1}{\|v\|} > 0$
- Si $s \in (0, 1)$: es combinación convexa de 1 y $\frac{1}{\|v\|} > 0$, por tanto $\lambda(v, s) > 0$

En todos los casos, $\lambda(v, s) > 0$, luego $H(v, s) \neq 0$ y está bien definida. Verificamos las condiciones de homotopía:

- H es continua (operaciones algebraicas con denominadores no nulos)
- $H(v, 0) = v = id_X(v)$
- $H(v, 1) = \frac{v}{\|v\|} = (g \circ f)(v)$

Por tanto, $g \circ f \simeq id_X$. En consecuencia, los espacios $X = \mathbb{R}^2 \setminus \{0\}$ e $Y = S^1$ tienen el mismo tipo de homotopía. $\square$

3.1.2. Complejos Simpliciales

En esta subsección se presenta un resumen sobre complejos simpliciales.

Definición 3.1.4. Dado un conjunto $\{a_0, \dots, a_n\}$ de puntos de $\mathbb{R}^D$, este conjunto se dice que es geoméricamente independiente si para cualesquiera escalares reales t_i , las ecuaciones

$$\sum_{i=0}^n t_i = 0 \quad y \quad \sum_{i=0}^n t_i a_i = 0$$

implican que $t_0 = t_1 = \dots = t_n = 0$.

Ejemplo 3.1.5.

- Sea $A = \{p\} \subset \mathbb{R}^D$, A es geoméricamente independiente.

Proposición 3.1.6. Sean $A = \{a_0, \dots, a_n\} \subset \mathbb{R}^D$ y $\tilde{A} = \{a_1 - a_0, \dots, a_n - a_0\}$, entonces A es geoméricamente independiente si y sólo si $\tilde{A}$ es linealmente independiente.

Demostración. ... $\square$

Como consecuencia de la proposición anterior dos puntos distintos en $\mathbb{R}^D$ forman un conjunto geoméricamente independiente, al igual que tres puntos no colineales, cuatro puntos no coplanares, y así sucesivamente.

También como consecuencia de la Proposición 3.1.6, en $\mathbb{R}^D$ puede haber máximo $D + 1$ puntos geoméricamente independientes.

Ahora, exploramos la relación entre el concepto de conjunto geoméricamente independiente y conjunto de puntos en posición general.

Definición 3.1.7. Decimos que un conjunto de puntos en $\mathbb{R}^D$ está en posición general si cualesquiera $k + 1$ puntos del conjunto son geoméricamente independientes, donde $k \leq D$.

De la definición anterior es claro que cualquier conjunto de puntos geoméricamente independientes está en posición general, pero la recíproca no es necesariamente cierta.

Definición 3.1.8. Dado un conjunto geoméricamente independiente de puntos $\{a_0, \dots, a_n\}$, definimos el n -**plano** P generado por estos puntos como el conjunto de todos los puntos x de $\mathbb{R}^N$ tales que

$$x = \sum_{i=0}^n t_i a_i,$$

para algunos escalares t_i con $\sum t_i = 1$. Dado que los a_i son geoméricamente independientes, los t_i están unívocamente determinados por x . Observar que $a_i \in P$.

En el caso anterior, podemos reescribir ... como

$$x = a_0 + \sum_{i=1}^n t_i (a_i - a_0)$$

Definición 3.1.9. Sean $\{a_0, \dots, a_n\}$ un conjunto geoméricamente independiente en $\mathbb{R}^N$. Definimos el n -**simplejo** σ generado por $a_0, \dots, a_n$ como el conjunto de todos los puntos x de $\mathbb{R}^N$ tales que

$$x = \sum_{i=0}^n t_i a_i, \quad \text{donde} \quad \sum_{i=0}^n t_i = 1$$

y $t_i \geq 0$ para todo i . Los números t_i están unívocamente determinados por x ; se llaman coordenadas baricéntricas del punto x de σ respecto a $a_0, \dots, a_n$.

Se llaman coordenadas baricéntricas porque es el centro de masa si en las coordenadas $a_0, \dots, a_n$ tenemos masas $t_0, \dots, t_n$.

La diferencia entre las definiciones ... radica en las restricciones sobre los coeficientes t_i :

- En la primera definición, se define el **n -plano** P y los coeficientes t_i pueden ser negativos, positivos o cero. Geométricamente, el n -plano es un subespacio afín de dimensión n en $\mathbb{R}^N$ que se extiende infinitamente en todas direcciones.
- En la segunda definición, se define el **n -simplejo** σ con la restricción de que $t_i \geq 0$ para todo i . Esta restricción de no negatividad hace que el simplex sea un subconjunto *acotado y convexo* del n -plano.

Definición 3.1.10. Los puntos $a_0, \dots, a_n$ que generan un simplejo σ se llaman los **vértices** de σ ; el número n se llama la **dimensión** de σ . Cualquier simplejo generado por un subconjunto de $a_0, \dots, a_n$ se llama una **cara** de σ . En particular, la cara de σ generada por $a_1, \dots, a_n$ se llama la **cara opuesta** a a_0 . El conjunto propio de caras de σ ; su unión se llama la **frontera** de σ y se denota $Bd(\sigma)$. El interior de σ se define como

$$Int(\sigma) = \sigma - Bd(\sigma).$$

Puesto que $Bd(\sigma)$ consiste de todos los puntos x de σ tales que al menos una de las coordenadas baricéntricas $t_i(x)$ es cero, $Int(\sigma)$ consiste de aquellos puntos de σ para los cuales $t_i(x) > 0$ para toda i .

Se sigue que, dado $x \in \sigma$, existe exactamente una cara s de σ tal que x está en $Int(s)$; la cara s es aquella para la cual $t_i(x)$ es positiva.

Proposición 3.1.11. Sea $U \subset \mathbb{R}^N$ un subconjunto abierto, convexo y acotado y sea $w \in U$

- Cada rayo emanando de w intersecta a $Bd(U)$ en exactamente un punto.
- Hay un homeomorfismo de $\bar{U}$ a la bola cerrada B^N llevando a $Bd(U)$ a S^{N-1} .

Demostración. ... □

En particular, esta proposición dice que cada simplejo de dimensión N es homeomorfo a B^N . Como consecuencia de esto, podemos

Proposición 3.1.12. Sea P un n -plano determinado por un conjunto de puntos geoméricamente independientes $\{a_0, \dots, a_n\}$ y sea σ el simplejo determinado por este conjunto. Si $x \in P$, sean $t_0(x), \dots, t_n(x)$ las coordenadas baricéntricas de x . Entonces

1. Las coordenadas baricéntricas de x son continuas respecto a x .
2. σ es igual a la unión de todos los segmentos de línea que unen a_i a puntos del simplejo s generado por $a_1, \dots, a_n$. Dos de tales segmentos de línea se intersectan solamente en el punto a_i .
3. Si A es un conjunto convexo de $\mathbb{R}^n$, ¿cuál es la intersección de todos los conjuntos convexos en $\mathbb{R}^n$ que contienen $a_0, \dots, a_n$?
4. Dado un simplejo σ , existe uno y sólo un conjunto geoméricamente independiente de puntos que genera σ .
5. $\text{Int } \sigma$ es convexo y es abierto en el plano P ; su clausura es σ . Más aún, $\text{Int } \sigma$ es homeomorfo a $\mathbb{R}^n$, mientras que $\text{Bd } \sigma$ es homeomorfo a $\text{Int } s$, donde s es la cara de σ opuesta a a_0 .

Definición 3.1.13. Un complejo simplicial K en $\mathbb{R}^N$ es una colección de símplexes en $\mathbb{R}^N$ tal que:

1. Cada cara de un simplejo de K está en K .
2. La intersección de cualesquiera dos simplejos de K es una cara de cada uno de ellos.

Ejemplo 3.1.14. La colección K_1 , mostrada en la Figura 2.1, que consiste de un 2-simplejo y sus caras, es un complejo simplicial. La colección K_2 , que consiste de dos 2-simplejos con una arista en común, junto con sus caras, es un complejo simplicial. La colección K_3 no lo es, mientras que K_4 sí lo es.




Figura 3.1: ¿Cuáles son complejos simpliciales?

Observación 3.1.15. Es importante distinguir entre un complejo simplicial compuesto únicamente de 0-simplejos y 1-simplejos, y un grafo en el sentido de la teoría de grafos. Aunque ambas estructuras consisten de vértices

y aristas, un complejo simplicial de dimensión 1 incluye explícitamente todos los vértices como 0-simplejos en su estructura, y cada arista (1-simplejo) debe tener sus dos vértices extremos como caras. En contraste, un grafo en teoría de grafos puede permitir aristas múltiples entre el mismo par de vértices, lazos (aristas que conectan un vértice consigo mismo), y no requiere la estructura de caras que caracteriza a los complejos simpliciales. Además, en un complejo simplicial, cada arista es geoméricamente un segmento de línea en algún $\mathbb{R}^N$, mientras que un grafo es puramente combinatorio y no posee una realización geométrica inherente. Por lo tanto, todo complejo simplicial de dimensión 1 puede verse como un grafo simple (sin aristas múltiples ni lazos), pero no todo grafo corresponde directamente a un complejo simplicial.

El siguiente lema es a veces útil para verificar que una colección de simplejos es un complejo simplicial:

Proposición 3.1.16. *Una colección K de simplejos es un complejo simplicial si y sólo si se cumple lo siguiente:*

- Toda cara de un simplejo de K está en K .
- Cualquier par de simplejos de K tienen interiores disjuntos.

Se sigue de este lema que si σ es un simplejo, entonces la colección consistente de σ y sus caras propias es un complejo simplicial: La condición (1) es inmediata; y la condición (2') se cumple porque para cada punto $x \in \sigma$, existe exactamente una cara s de σ tal que $x \in \text{Int } s$.

Definición 3.1.17. *Si L es una subcolección de K que contiene todas las caras de sus elementos, entonces L es un complejo simplicial en su propio derecho; se llama un **subcomplejo** de K . Un subcomplejo de K es la colección de todos los simplejos de K de dimensión a lo más p ; se llama el p -esqueleto de K y se denota $K^{(p)}$. Los puntos en la colección $K^{(0)}$ se llaman los **vértices** de K .*

Hay dos maneras de pensar en el subconjunto de $\mathbb{R}^N$ que determina un complejo simplicial, es decir, la forma que delimita más allá de los detalles combinatorios. **La definición 3.1.18... mientras que la definición ?? ...**

Definición 3.1.18. *Sea $|K|$ el subconjunto de $\mathbb{R}^N$ que es la unión de los simplejos de K . Dando a cada simplejo su topología usual, podemos topologizar*

$|K|$ declarando que un subconjunto A de $|K|$ es cerrado en $|K|$ si y sólo si $A \cap \sigma$ es cerrado en σ , para cada σ en K . Es fácil ver que esto define una topología en $|K|$, y que $|K|$ es un espacio de Hausdorff que satisface el segundo axioma de numerabilidad. El espacio $|K|$ se llama el **espacio subyacente** de K , o el **politopo** de K .

Proposición 3.1.19. *Topología más fina...*

Ejemplo 3.1.20. Sea K la colección de todos los 1-simplejos en $\mathbb{R}$ de la forma $[m, m+1]$, donde m es un entero diferente de 0, junto con todos los simplejos de la forma

$$[\frac{1}{n+1}, \frac{1}{n}]$$

para n un entero positivo, junto con todas las caras de estos simplejos. Entonces K es un complejo cuyo espacio subyacente es igual a $\mathbb{R}$ como conjunto pero no como espacio topológico. Por ejemplo, el conjunto de puntos $\{\frac{1}{n}\}$ es cerrado en $|K|$ pero no en $\mathbb{R}$.

Podemos definir un complejo primero y ponerlo en un espacio Euclidiano después.

Definición 3.1.21. Un **complejo simplicial abstracto** es una colección finita de conjuntos A tal que $\alpha \in A$ y $\beta \subseteq \alpha$ implica $\beta \in A$.

Observación 3.1.22. Observar que esta definición emula la definición de complejo simplicial geométrico, sin embargo no necesita la segunda condición ya que...

Los conjuntos en A son sus **simplejos**. La **dimensión** de un simplejo es $\dim \alpha = \text{card } \alpha - 1$ y la dimensión del complejo es la dimensión máxima de cualquiera de sus simplejos. Una **cara** de α es un subconjunto no vacío propio $\beta \subsetneq \alpha$ de α . El **conjunto de vértices** es la unión de todos los simplejos,

$$\text{Vert } A = \bigcup A$$

Un **subcomplejo** es un complejo simplicial abstracto $B \subseteq A$. Dos complejos simpliciales abstractos son *isomorfos* si existe una biyección $b : \text{Vert } A \rightarrow \text{Vert } B$ tal que $\alpha \in A$ si y sólo si $b(\alpha) \in B$.

Dado un complejo simplicial (geométrico) K , podemos construir un complejo simplicial abstracto A descartando todos los simplejos y reteniendo solo

sus conjuntos de vértices. Llamamos a A un **esquema de vértices** de K . Simétricamente, llamamos a K una **realización geométrica** de A . Construir realizaciones geométricas es sorprendentemente fácil si la dimensión del espacio ambiente es suficientemente alta.

La **dimensión** de K es la dimensión máxima de cualquiera de sus simplejos. Una **triangulación** de un espacio topológico X es un complejo simplicial K junto con un homeomorfismo entre X y $|K|$. El espacio topológico es **triangulable** si tiene una triangulación. Una triangulación de K es un simplejo complejo $L \subseteq K$. Es *completa* si contiene todos los simplejos en K generados por vértices en L . Un subcomplejo particular es el **j -esqueleto** consistente de todos los simplejos de dimensión j o menor,

$$K^{(j)} = \{\sigma \in K \mid \dim \sigma \leq j\}.$$

El 0-esqueleto también se conoce como el *conjunto de vértices*, $\text{Vert } K = K^{(0)}$. Los esqueletos generalmente no son completos.

Ejemplo 3.1.23.

1. Sea V un conjunto finito de cardinalidad $n+1$. El **n -símplice combinatorio** con conjunto de vértices V es un complejo simplicial abstracto (ASC) cuyas caras son todos los subconjuntos no vacíos de V (es decir, es el conjunto potencia de V). Si $V = \{0, 1, \dots, n\}$, entonces este ASC se denomina **n -símplice combinatorio estándar**.
2. Sea G un grafo no dirigido. El **complejo de cliques** de G es un ASC cuyas caras son todas las cliques (subgrafos completos) de G . El **complejo de independencia** de G es un ASC cuyas caras son todos los conjuntos independientes de G (es el complejo de cliques del grafo complemento de G). Los complejos de cliques son el ejemplo prototípico de complejos flag. Un **complejo flag** es un complejo K con la propiedad de que todo conjunto, cuyos subconjuntos de 2 elementos son caras de K , es en sí mismo una cara de K .
3. Sea P un conjunto parcialmente ordenado (poset). El **complejo de orden** de P es un ASC cuyas caras son todas las cadenas finitas en P . Sus grupos de homología y otros invariantes topológicos contienen información importante sobre el poset P .

Teorema 3.1.24 (Geometric Realization Theorem). *Cada complejo simplicial abstracto de dimensión d tiene una realización geométrica en $\mathbb{R}^{2d+1}$.*

Ejemplo 3.1.25. En las figuras 3.2 y 3.3 vemos complejos simpliciales homeomorfos a un cilindro y toro, respectivamente. Algunas preguntas:

- ¿Por que la división en triángulos? ¿por qué no en rectángulos?
- ¿Es un rectángulo un simplejo? ¿uno abstracto?
- En el caso del toro, ¿por qué la división inicial de 3×3 en lugar de 2×3 ?




Figure 3.2

Figura 3.2: El cilindro




Figura 3.3: El toro

Sea K un complejo simplicial con vértices $u_0, u_1, \dots, u_n$. Cada punto $x \in |K|$ pertenece al interior de exactamente un simplejo en K . Si $\sigma = \text{conv}\{u_0, u_1, \dots, u_k\}$ es este simplejo, entonces $x = \sum_{i=0}^k \lambda_i u_i$ con $\sum_{i=0}^k \lambda_i = 1$ y $\lambda_i > 0$ para todo i . Definiendo $b_i(x) = \lambda_i$ para $0 \leq i \leq k$ y $b_i(x) = 0$ para $k+1 \leq i \leq n$, tenemos $x = \sum_{i=0}^n b_i(x) u_i$. Los valores $b_i(x)$ se llaman **coordenadas baricéntricas** de x en K .

Definición 3.1.26. Una **aplicación de vértices** es una función $\varphi : \text{Vert } K \rightarrow \text{Vert } L$ con la propiedad de que los vértices de cada simplejo en K se mapean a vértices de un simplejo en L . Esta aplicación puede extenderse a una

aplicación continua $f : |K| \rightarrow |L|$ definida por

$$f(x) = \sum_{i=0}^n b_i(x) \varphi(u_i),$$

llamada la **aplicación simplicial inducida** por φ . Esta aplicación es lineal en cada simplejo de K .

3.1.3. Complejos de Čech y Vietoris-Rips

Definición 3.1.27. Dada una colección finita de conjuntos F , definimos el **nervio** como

$$\text{Nrv } F = \{X \subseteq F \mid \bigcap X \neq \emptyset\}.$$

Es decir, el nervio consiste de todas las subcolecciones no vacías cuyos conjuntos tienen intersección común no vacía.

Proposición 3.1.28. El nervio siempre es un complejo simplicial abstracto.

Demostración. Si $\bigcap X \neq \emptyset$ y $Y \subseteq X$, entonces $\bigcap Y \neq \emptyset$... $\square$

El siguiente resultado fundamental relaciona la topología de una colección de subconjuntos de $\mathbb{R}^D$ con su nervio, como complejo simplicial abstracto realizado geoméricamente. El nervio captura la información topológica esencial de la colección original de conjuntos.

Teorema 3.1.29 (Teorema del Nervio). Sea F una colección finita de conjuntos cerrados y convexos en el espacio euclídeo. Entonces el nervio de F y la unión de los conjuntos en F tienen el mismo tipo de homotopía: $\text{Nrv } F \simeq \bigcup F$.

Consideramos ahora el caso especial en que los conjuntos convexos son bolas cerradas geométricas, todas del mismo radio r . Sea $A \subset \mathbb{R}^d$ un conjunto finito de puntos, es decir, un dataset y sea

$$F_r = \{\overline{B(x, r)} \mid x \in A\}$$

la colección de las bolas cerradas con centro en los puntos de S y radio r .

Definición 3.1.30. El **complejo de Čech** de S y r es un complejo simplicial abstracto isomorfo al $\text{Nrv}(F_r)$, es decir,

$$\check{Cech}(r) = \{\sigma \subseteq A \mid \bigcap_{x \in \sigma} B_x(r) \neq \emptyset\}.$$

Una observación clave es que un conjunto de bolas tiene intersección no vacía si y solo si sus centros están contenidos en una bola común del mismo radio. En efecto, un punto y pertenece a todas las bolas si y solo si $\|x - y\| \leq r$ para todos los centros x .

Proposición 3.1.31. *Sean $r' \leq r$, entonces*

$$\check{Cech}(r') \subseteq \check{Cech}(r)$$

Demostración. ... □

Si aumentamos continuamente el radio de 0 a ∞ , obtenemos una familia discreta de complejos de Čech anidados.

Definición 3.1.32. *El **complejo de Vietoris-Rips** de S y r es el complejo simplicial abstracto*

$$Vietoris-Rips(r) = \{\sigma \subseteq A \mid \text{diam } \sigma \leq 2r\}.$$

Proposición 3.1.33. *Para cualquier $r > 0$ se satisface*

- $\check{Cech}(r) \subseteq Vietoris-Rips(r)$
- $Vietoris-Rips(r) \subseteq \check{Cech}(\sqrt{2}r)$

Demostración. ... □

La segunda conclusión de esta proposición nos dice que el complejo de Vietoris-Rips aproxima el complejo de Čech, con la diferencia acotada por el factor constante $\sqrt{2}$ en el radio. Ambos complejos capturan la noción de *proximidad* entre puntos en un conjunto de datos.

- El complejo de Čech es más preciso topológicamente (por el Teorema del Nervio), pero puede ser costoso de calcular ya que requiere verificar intersecciones de múltiples bolas.
- El complejo de Vietoris-Rips es más fácil de calcular, ya que solo requiere calcular distancias por pares entre puntos. Es una aproximación del complejo de Čech con error acotado.

En la práctica, el complejo de Vietoris-Rips se usa con mayor frecuencia debido a su eficiencia computacional, especialmente en análisis topológico de datos donde se trabaja con grandes conjuntos de puntos. Usaremos la implementación de [GUDHI](#).

3.1.4. Grupos Libres Abelianos

Ejemplos de grupos libres abelianos:

- Los enteros $\mathbb{Z}$ con la suma usual y base $\{1\}$.
- Los números racionales positivos $\mathbb{Q}^+$ con la multiplicación y base los números primos.
- Los polinomios de una variable x con coeficientes enteros, bajo la suma de polinomios y base $\{1, x, x^2, \dots\}$.
- El retículo entero $\mathbb{Z}^n$ con la suma vectorial y base canónica $\{e_1, e_2, \dots, e_n\}$.
- Cualquier retículo $L \subset \mathbb{R}^n$ generado por vectores linealmente independientes.

Ejemplos de grupos que no son libres abelianos porque no tienen representación única:

- $\mathbb{Z}/n\mathbb{Z}$ (los enteros módulo n), donde $n > 1$. Por ejemplo, en $\mathbb{Z}/4\mathbb{Z}$, el elemento 2 puede escribirse como $2 \cdot 1$ o como $4 \cdot 1 - 2 \cdot 1$ (pero $4 \cdot 1 = 0$ en este grupo).
- $\mathbb{Z} \times \mathbb{Z}/2\mathbb{Z}$: el elemento $(0, 1)$ se escribe como $2 \cdot (0, 1)$ o como $0 \cdot (1, 0) + 1 \cdot (0, 1)$, pero también $(0, 1) = (2, 0) - 2 \cdot (1, 0)$ (usando relaciones no triviales).
- $\mathbb{Q}$ (los racionales con la suma): cualquier elemento $\frac{a}{b}$ tiene infinitas representaciones como combinación de generadores (p.ej., $\frac{1}{2} = 2 \cdot \frac{1}{4} = 3 \cdot \frac{1}{6} = \dots$).
- $\mathbb{R}$ (los reales con la suma): similar a $\mathbb{Q}$, no tiene base y los elementos admiten múltiples descomposiciones.
- Grupos de torsión no triviales, como $\mathbb{Z}/2\mathbb{Z} \times \mathbb{Z}/3\mathbb{Z}$: ...

3.1.5. Homología Simplicial

Ahora calcularemos la homología de los complejos simpliciales. Esta subsección está basada en [Edelsbrunner and Harer, 2010, Capítulo IV] y [Munkres, 2018, Capítulo 1.6]. Comenzaremos definiendo los grupos de Homología.

Definición 3.1.34. Sea K un complejo simplicial. Una p -cadena en K es una función c del conjunto de p -símplices orientados de K a $\mathbb{Z}$, tal que:

- $c(\sigma) = -c(\sigma')$ si σ y σ' son orientaciones opuestas del mismo símplex.
- $c(\sigma) = 0$ para todos excepto finitos p -símplices orientados σ .

Sumamos p -cadenas sumando sus valores; el grupo resultante se denota $C_p(K)$ y se llama el grupo de p -cadenas (orientadas) de K . Si $p < 0$ o $p > \dim K$, dejamos que $C_p(K)$ denote el grupo trivial.

Si σ es un símplex orientado, la cadena elemental c correspondiente a σ es la función definida como sigue:

$$\begin{aligned} c(\sigma) &= 1, \\ c(\sigma') &= -1 \quad \text{si } \sigma' \text{ es la orientación opuesta de } \sigma, \\ c(\tau) &= 0 \quad \text{para todos los otros símplices orientados } \tau. \end{aligned}$$

Por abuso de notación, a menudo usamos el símbolo σ para denotar no solo un símplex, o un símplex orientado, sino también para denotar la p -cadena elemental c correspondiente al símplex orientado σ . Con esta convención, si σ y σ' son orientaciones opuestas.

Observación 3.1.35. En la definición de p -cadenas, definición 3.1.34, podemos cambiar el papel de $\mathbb{Z}$ por otro anillo o campo, en particular $\mathbb{Z}_2$.

Proposición 3.1.36. Para cualquier entero no negativo p , $(C_p(K), +)$ es un grupo libre abeliano, para obtener una base se orienta cada simplejo arbitrariamente.

Definición 3.1.37. Definimos el homomorfismo de grupos, llamado operador frontera,

$$\partial_p : C_p(K) \rightarrow C_{p-1}(K)$$

Si $\sigma = [v_0, \dots, v_p]$ es un p -simplejo orientado con $p > 0$ entonces

$$\partial_p(\sigma) = \sum_{j=0}^p (-1)^j [v_0, \dots, \hat{v}_j, \dots, v_p]$$

Para $p \leq 0$ es el operador trivial.

Proposición 3.1.38. Para cualquier entero p se satisface $\partial_{p-1} \circ \partial_p = 0$.

Definición 3.1.39. El **complejo de cadena** es la sucesión de grupos de cadena conectados por los operadores frontera:

$$\cdots \xrightarrow{\partial} C_{p+1} \xrightarrow{\partial} C_p \xrightarrow{\partial} C_{p-1} \xrightarrow{\partial} \cdots$$

Los índices del operador frontera se omiten ya que se deducen de los respectivos grupos de cadenas.

Distinguimos dos tipos particulares de cadenas y los usamos para definir grupos de homología.

Definición 3.1.40. Un **p -ciclo** es una p -cadena con borde vacío, $\partial c = 0$. Denotamos por $Z_p = Z_p(K)$ al grupo de p -ciclos de K , el cual es un subgrupo del grupo de p -cadenas. En otras palabras, Z_p es el kernel operador frontera ∂_p .

Definición 3.1.41. Un **p -frontera** es una p -cadena que es la frontera de una $(p+1)$ -cadena, $c = \partial d$ con $d \in C_{p+1}$. Denotamos por $B_p = B_p(K)$ al subgrupo de las p -fronteras. En otras palabras, B_p es la imagen del operador frontera ∂_{p+1} .

Se sigue de la definición que los subgrupos Z_p y B_p son abelianos.




Figura 3.4: Complejo de Cadena

Como las fronteras forman subgrupos de los grupos de ciclos, podemos tomar cocientes. En otras palabras, podemos particionar cada grupo de ciclos en clases de ciclos que difieren entre sí por fronteras. Esto conduce a la noción de grupos de homología y sus rangos.

Definición 3.1.42. El p -ésimo grupo de homología es el p -ésimo grupo de ciclos módulo el p -ésimo grupo de bordes, $H_p = Z_p/B_p$. El p -ésimo número de Betti es el rango de este grupo, $\beta_p = \text{rank } H_p$.

Ejemplo 3.1.43.

- Consideremos el complejo K de la Figura 3.5, cuyo espacio subyacente es el borde de un cuadrado con aristas e_1, e_2, e_3, e_4 .




Figura 3.5: El complejo simplicial K con $H_1(K) \cong \mathbb{Z}$.

El grupo $C_1(K)$ es abeliano libre de rango 4, está formado por las 1-cadenas c es de la forma $\sum_{i=1}^4 n_i e_i$. Determinemos el grupo de p -ciclos Z_p , para esto veamos que

$$\begin{aligned}
 \partial_1 c &= \sum_{i=1}^4 n_i \partial_1 [e_i] \\
 &= n_1 (v_3 - v_0) + n_2 (v_0 - v_1) + n_3 (v_1 - v_2) + n_4 (v_2 - v_3) \\
 &= (n_2 - n_1)v_0 + (n_3 - n_2)v_1 + (n_4 - n_3)v_2 + (n_1 - n_4)v_3
 \end{aligned}$$

Y luego $\partial_1 c = 0$ si y sólo si $n_1 = n_2 = n_3 = n_4$. Por lo tanto, $Z_1(K)$ es generado por la cadena $e_1 + e_2 + e_3 + e_4$ y luego, es cíclico infinito. Es decir, $Z_p \cong \mathbb{Z}$. Ahora determinemos el grupo $B_1(K)$. Para esto, observemos que no hay 2-símplices en K y luego, $B_1(K)$ es el grupo trivial. Por lo tanto,

$$H_1(K) = Z_1(K) \cong \mathbb{Z}.$$

Luego, $\beta_1 = 1$, indicando que tiene un ciclo de dimensión 1.

- Consideremos el complejo K de la Figura 3.6, cuyo espacio subyacente es el cuadrado cerrado en $\mathbb{R}^2$.




Figura 3.6: El complejo simplicial K con $H_1(K) \cong 0$.

3.1.6. Calculando la Homología

Un *dominio de ideales principales* (DIP) es un dominio de integridad en el que todo ideal es principal, es decir, puede generarse por un solo elemento. Formalmente, un anillo conmutativo R con unidad y sin divisores de cero es un dominio de ideales principales si para todo ideal $I \subseteq R$ existe un elemento $a \in R$ tal que $I = (a) = \{ra \mid r \in R\}$.

Ejemplos de dominios de ideales principales:

- El anillo de los enteros $\mathbb{Z}$.
- El anillo de polinomios en una variable sobre un cuerpo, es decir, $F[x]$ donde F es un cuerpo (por ejemplo, $\mathbb{Q}[x]$, $\mathbb{R}[x]$, $\mathbb{C}[x]$).
- Cualquier cuerpo K , ya que sus únicos ideales son (0) y $(1) = K$, ambos principales.

Ejemplo de dominio de integridad que *no* es un DIP:

- El anillo $\mathbb{Z}[x]$ de polinomios con coeficientes enteros. El ideal $(2, x)$ no es principal.
- El anillo $\mathbb{Z}[\sqrt{-5}] = \{a + b\sqrt{-5} \mid a, b \in \mathbb{Z}\}$, que no es un DIP (de hecho, ni siquiera es un dominio de factorización única).

Sea A una matriz $m \times n$ no nula sobre un dominio de ideales principales R . Existen matrices invertibles $m \times m$ y $n \times n$, S y T (con entradas en R)

tales que el producto SAT es

$$\begin{pmatrix} \alpha_1 & 0 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \alpha_2 & 0 & & & & \\ 0 & 0 & \ddots & & \vdots & & \vdots \\ \vdots & & & \alpha_r & & & \\ 0 & & \cdots & & 0 & \cdots & 0 \\ \vdots & & & & \vdots & & \vdots \\ 0 & & \cdots & & 0 & \cdots & 0 \end{pmatrix}.$$

Los elementos diagonales α_i satisfacen $\alpha_i \mid \alpha_{i+1}$ para todo $1 \leq i < r$. Esta es la forma normal de Smith de la matriz A . Los elementos α_i son únicos salvo multiplicación por una unidad y se llaman divisores elementales, invariantes o factores invariantes. Pueden calcularse (salvo multiplicación por una unidad) como

$$\alpha_i = \frac{d_i(A)}{d_{i-1}(A)},$$

donde $d_i(A)$ (llamado i -ésimo divisor determinante) es igual al máximo común divisor de los determinantes de todos los menores $i \times i$ de la matriz A , y $d_0(A) := 1$.

Ejemplo: Para una matriz 2×2 , $\text{SNF} \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \text{diag}(d_1, d_2/d_1)$ con $d_1 = \gcd(a, b, c, d)$ y $d_2 = |ad - bc|$.

3.2. Teoría Discreta de Morse

...

Capítulo 4

Aproximando Funciones en Espacios de Alta Dimensión

Problema Central: ¿Cómo aprender funciones $f : \mathbb{R}^N \rightarrow \mathbb{R}^M$ con N, M grandes?

Dentro del aprendizaje automático supervisado, uno de los algoritmos más potentes son las redes neuronales. Estos son ensambles basados en varias arquitecturas. La arquitectura más básica es la red *Fully Connected*, también llamada *MultiLayer Perceptron* (MLP).

En este modulo definiremos estas redes neuronales MLP, describiremos su funcionamiento y probaremos algunos de los teoremas de aproximación universal [Cybenko \[1989\]](#), [Andrei \[1957\]](#).

Una vez más, diremos que un conjunto de datos (dataset) es un conjunto finito $A \subset \mathbb{R}^D$, donde D es típicamente un valor grande $D \geq 4$. Abusando de la notación, también denotaremos al conjunto A por la matriz $A \in \mathcal{M}_{N \times D}(\mathbb{R})$ donde $|A| = N$ en la cual cada fila es un elemento de A dado por sus coordenadas en la base canónica.

1. Aproximadores Universales

- Teoremas de Cybenko [Cybenko \[1989\]](#) y Kolmogorov [Andrei \[1957\]](#)
- MLPs como aproximadores universales
- Ejemplo: Clasificación MNIST, solución de EDO.

2. CNNs: Aproximación con Geometría Incorporada

- Equivariancia a traslaciones:

$$\text{Conv}(I \circ T_v) = (\text{Conv}(I)) \circ T_v$$

- CNNs como aproximadores universales con restricciones [Zhou \[2020\]](#) y *trade-off* eficiencia-generalización
- Ejemplo: Clasificación MNIST

3. Generalización a Otras Geometrías (Opcional)

- Principio de equivariancia [Bronstein et al. \[2017\]](#)
- GNNs para grafos, CNNs en variedades

4.1. Redes MLP

4.1.1. El Perceptrón

Definición 4.1.1. Un **perceptrón** es una función $P : \mathbb{R}^D \rightarrow \mathbb{R}$ dada por

$$P(x_1, \dots, x_D) = f \left(w_0 + \sum_{i=1}^D w_i x_i \right)$$

donde $f : \mathbb{R} \rightarrow \mathbb{R}$ es una función continua, llamada **función de activación** y $w_0, \dots, w_D \in \mathbb{R}$ son llamados **pesos**. Además, a w_0 se le llama **sesgo** o **bias**. A un perceptrón también se le denomina **neurona**.

Observación 4.1.2. Podemos reescribir la definición del perceptrón como un producto interior

$$P(x_1, \dots, x_D) = f \left(\begin{pmatrix} w_0 & w_1 & \dots & w_D \end{pmatrix} \begin{pmatrix} 1 \\ x_1 \\ \dots \\ x_D \end{pmatrix} \right)$$

Para $x = (x_1, \dots, x_D) \in \mathbb{R}^D$, denotemos $\tilde{x} = (1, x_1, \dots, x_D) \in \mathbb{R}^{D+1}$.

Las funciones de activación más comunes son

- Sigmoide:

$$f(x) = \frac{1}{1 + e^{-x}}$$

- Tangente hiperbólica:

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

- ReLU (Rectified Linear Unit):

$$f(x) = \begin{cases} x, & \text{si } x \geq 0, \\ 0, & \text{si } x < 0. \end{cases}$$

- Leaky ReLU:

$$f(x) = \begin{cases} x, & \text{si } x \geq 0, \\ \alpha x, & \text{si } x < 0. \end{cases}$$

donde α es un parámetro pequeño (típicamente $\alpha = 0,01$).

- Softmax:

$$f_x(x_i) = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}}$$

donde $x = (x_1, \dots, x_n)$, donde n es el número de clases en un problema de clasificación.

- ELU, Exponential Linear Unit:

$$f(x) = \begin{cases} x, & \text{si } x \geq 0, \\ \alpha(e^x - 1), & \text{si } x < 0. \end{cases}$$

donde $\alpha > 0$ es un parámetro [Clevert et al. \[2015\]](#).

En algunos casos también puede usarse la identidad como función de activación, en este caso se le llama *activación lineal*.

Observación 4.1.3. *La regresión lineal se puede pensar como un perceptrón con función de activación lineal. El SVM se puede pensar como un perceptrón con una función de activación signo*

$$f(x) = \frac{x}{|x|}.$$

¿Perceptrón como algoritmo de clasificación?

Podemos usar la implementación de scikit-learn del [Perceptron](#).

4.1.2. Ensamblando perceptrones: Feed Forward

Una **capa de m neuronas** es una función $P : \mathbb{R}^D \rightarrow \mathbb{R}^m$ de la forma

$$\begin{aligned} P(x_1, \dots, x_D) &= f(W \cdot \tilde{x}) \\ &= f \left(\begin{pmatrix} w_{1,0} & w_{1,1} & \dots & w_{1,D} \\ w_{2,0} & w_{2,1} & \dots & w_{2,D} \\ \dots & \dots & \dots & \dots \\ w_{m,0} & w_{m,1} & \dots & w_{m,D} \end{pmatrix} \begin{pmatrix} 1 \\ x_1 \\ \dots \\ x_D \end{pmatrix} \right) \end{aligned}$$

donde $\tilde{x} = (1, x_1, \dots, x_D)^T$, $W \in \mathcal{M}_{m \times (D+1)}(\mathbb{R})$ es una matriz de pesos $w_{i,j}$ y sesgos $w_{i,0}$. Abusando de la notación, la función $f : \mathbb{R}^m \rightarrow \mathbb{R}^m$ aplica la misma función de activación en cada una de las m componentes del vector $W \cdot \tilde{x}^T$ de la siguiente forma:

$$f(W \cdot \tilde{x}) = \left(f \left(w_{1,0} + \sum_{k=1}^D w_{1,k} x_k \right), \dots, f \left(w_{m,0} + \sum_{k=1}^D w_{m,k} x_k \right) \right)$$

En la figura 4.1 vemos una capa de $m = 5$ neuronas con entrada de dimensión $D = 3$. Cada neurona está ilustrado en color rojo, cada círculo azul representa una componente de la entrada $x = (x_1, x_2, x_3)$, y el círculo negro denota la salida $P(x) \in \mathbb{R}$.




Figura 4.1: Una capa de perceptrones

Podemos apilar L capas de $m_1, \dots, m_L$ neuronas respectivamente, de la siguiente forma:

1. La primera capa oculta es una función $P_1 : \mathbb{R}^{m_0} \rightarrow \mathbb{R}^{m_1}$ donde $m_0 = D$.
2. La segunda capa oculta es una función $P_2 : \mathbb{R}^{m_1} \rightarrow \mathbb{R}^{m_2}$.
3. Continuamos de forma análoga hasta llegar a la L -ésima capa oculta, que es una función $P_L : \mathbb{R}^{m_{L-1}} \rightarrow \mathbb{R}^{m_L}$.

Las capas $P_1, \dots, P_L$ se denominan **capas ocultas**. Finalmente apilamos una **capa de salida** $P_{L+1} : \mathbb{R}^{m_L} \rightarrow \mathbb{R}^{m_{L+1}}$.

En este caso, decimos que el ensamble de capas es una **red neuronal MultiLayer Perceptron** (MLP) con L capas ocultas y arquitectura $(m_0, m_1, \dots, m_L, m_{L+1})$ donde $m_0 = D$ es la dimensión de entrada y m_{L+1} es la dimensión de salida. Al parámetro L lo llamamos también la **profundidad** de la red. En la figura 4.2 vemos una red MLP con arquitectura $(3, 5, 8, 5, 2)$, $L = 3$, las capas ocultas son las neuronas rojas, la capa de entrada es la capa azul y la capa de salida es la capa negra.




Figura 4.2: Una red MLP

Observación 4.1.4. Siguiendo la notación de la definición de una red MLP, tanto la dimensión de entrada $m_0 = D$ como la dimensión de salida m_{L+1} están totalmente determinadas por el problema que estemos modelando.

Las dimensiones intermedias $m_1, \dots, m_L$ (el ancho de las capas ocultas) y el número de capas ocultas L son hiperparámetros del modelo y pueden ser ajustados para brindar mayor o menor capacidad de aproximación. Redes más anchas y profundas tienen mayor capacidad expresiva, pero también mayor riesgo de sobreajuste y mayor costo computacional.

Como hemos visto anteriormente, cualquier problema de aprendizaje supervisado puede ser modelado por una función $f : \mathbb{R}^D \rightarrow \mathbb{R}^m$, donde D es el número de variables predictoras (features) y m es el número de variables a predecir (target). Podemos definir una red MLP de manera que $m_0 = D$ y $m_{L+1} = m$ para aproximar la función f .

4.1.3. Teoremas Universales de Aproximación

Sea $\sigma \in C(\mathbb{R})$ una función de activación. Definimos la clase de funciones

$$\mathcal{M}(\sigma) = \text{span}\{x \mapsto \sigma(w \cdot x - \theta) \mid \theta \in \mathbb{R}, w \in \mathbb{R}^n\}$$

Teorema 4.1.5. *Sea $\sigma \in C(\mathbb{R})$. Entonces $\mathcal{M}(\sigma)$ es densa en $C(\mathbb{R}^n)$, en la topología de convergencia uniforme en compactos, si y solo si σ no es un polinomio.*

El teorema se cumple cuando σ es la función de activación sigmoide, tangente hiperbólica, relu, etc.

4.1.4. Entrenamiento: Back Propagation

4.1.5. Implementación computacional

Implementaciones a usar: TensorFlow, PyTorch.

4.2. Redes CNN

4.2.1. Implementación computacional

Implementaciones a usar: TensorFlow, PyTorch.

Bibliografía

Afonso Bandeira. Topics in mathematics of data science (fall 2015), mit, 2015. URL <https://ocw.mit.edu/courses/18-s096-topics-in-mathematics-of-data-science-fall-2015>.

N Andrei. Kolmogorov. on the representation of continuous functions of several variables as superpositions of continuous functions of one variable and addition. In *Dokl. Akad. Nauk SSSR*, volume 114, pages 953–956, 1957.

Keith Ball et al. An elementary introduction to modern convex geometry. *Flavors of geometry*, 31(1-58):26, 1997.

Stephen P Boyd and Lieven Vandenberghe. *Convex optimization*. Cambridge university press, 2004.

Michael M Bronstein, Joan Bruna, Yann LeCun, Arthur Szlam, and Pierre Vandergheynst. Geometric Deep Learning: Going beyond Euclidean Data. *IEEE Signal Processing Magazine*, 34(4):18–42, 2017.

Michael M. Bronstein, Joan Bruna, Taco Cohen, and Petar Veličković. Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges. *arXiv preprint arXiv:2104.13478*, 2021. URL <https://geometricdeeplearning.com/book/>.

Wenming Cao, Zhiyue Yan, Zhiquan He, and Zhihai He. A comprehensive survey on geometric deep learning. *IEEE Access*, 8:35929–35949, 2020.

Djork-Arné Clevert, Thomas Unterthiner, and Sepp Hochreiter. Fast and accurate deep network learning by exponential linear units (elus). *arXiv preprint arXiv:1511.07289*, 4(5):11, 2015.

- George Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of control, signals and systems*, 2(4):303–314, 1989.
- Herbert Edelsbrunner and John Harer. *Computational topology: an introduction*. American Mathematical Soc., 2010.
- Ky Fan. On a theorem of weyl concerning eigenvalues of linear transformations i. *Proceedings of the National Academy of Sciences*, 35(11):652–655, 1949.
- Martin Grötschel, László Lovász, and Alexander Schrijver. *Geometric algorithms and combinatorial optimization*, volume 2. Springer Science & Business Media, 2012.
- Alexander Hinneburg, Charu C Aggarwal, and Daniel A Keim. What is the nearest neighbor in high dimensional spaces? 2000.
- Roger A Horn and Charles R Johnson. *Matrix analysis*. Cambridge university press, 2012.
- Harold Hotelling. Analysis of a complex of statistical variables into principal components. *Journal of educational psychology*, 24(6):417, 1933.
- William B Johnson, Joram Lindenstrauss, et al. Extensions of lipschitz mappings into a hilbert space. *Contemporary mathematics*, 26(189-206):1, 1984.
- Leland McInnes, John Healy, and James Melville. Umap: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*, 2018. URL <https://arxiv.org/abs/1802.03426>.
- James R Munkres. *Elements of algebraic topology*. CRC press, 2018.
- Karl Pearson. On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin philosophical magazine and journal of science*, 2(11):559–572, 1901.
- Ding-Xuan Zhou. Universality of deep convolutional neural networks. *Applied and Computational Harmonic Analysis*, 48(2):787–794, 2020. URL <https://doi.org/10.1016/j.acha.2019.06.004>.